

311551148 lab4 Report

1. Introduction

這次 lab 我們要利用 ResNet18 以及 ResNet50 來實作糖尿病所引發的視網膜病變偵測，我們也需要實作 pytorch dataloader 以及資料集的 preprocessing，最後要使用 confusion matrix 來 evaluate model。

2. Experiments setups

甲、The details of your model

```
class resnet(nn.Module):
    def __init__(self, model, pretrained, num_class):
        super(resnet, self).__init__()

        self.model_name = model
        self.num_class = num_class

        if self.model_name == "resnet18":
            self.resnet = models.resnet18(pretrained=pretrained)
        elif self.model_name == "resnet50":
            self.resnet = models.resnet50(pretrained=pretrained)

        ## Reinitialize the last layer
        fc_in_dim = self.resnet.fc.in_features
        fc_out_dim = self.num_class
        self.resnet.fc = nn.Linear(fc_in_dim, fc_out_dim)

    def forward(self, x):
        x = self.resnet(x)
        return x
```

model 的部分因為可以使用 pytorch 定義好的 model，所以很單純，我是使用 ResNet v1.5，相比原本 paper 提出的架構，ResNet v1.5 把 stride 移到 conv 3*3 的部分，可以有更快更好更穩定的結果。唯一要改動的事最後一層 classification layer，原本 pretrained 的模型是設計給 1000 class classification，但我們只需要做 5 個類別的分類，所以把他最後的 fully connect layer 改成 output 5 channel。

乙、The details of your dataloader

```
img_path = f"{self.root}/processed_data/{self.img_name[index]}.jpeg"
label = self.label[index]

## Define transformations
transformations = transforms.Compose([
    transforms.RandomHorizontalFlip(),
    transforms.RandomVerticalFlip(),
    transforms.ToTensor(), ## Scales the pixel to the range [0, 1]
    transforms.Normalize((0.3749, 0.2602, 0.1857), (0.2526, 0.1780, 0.1291)) ## Normalization
])

img = Image.open(img_path)
img = transformations(img)

return img, label
```

附圖的 code 是 __get_item__ 的 code，使用 torchvision 的 transform 來做 data augmentation，包含 random horizontal flip 以及 random vertical flip，再把資料轉成 tensor 方便之後訓練使用，最後在把資料

normalize，因為 resize 在 data preprocessing 就已經做好了，所以讀進來的圖片都已經是 crop 好 512*512，使用 PIL 來讀取指定路徑的圖片檔案，最後 get item 回傳這個 index 所對應到的圖片以及相對應的 label。

丙、Describe your evaluation through the confusion matrix

```
## Calculate confusion matrix
num_class = len(set(labels.tolist()))
confusion_matrix = np.zeros((num_class, num_class))
for idx in range(len(labels)):
    confusion_matrix[labels[idx]][preds[idx]] += 1

## Normalize
confusion_matrix = confusion_matrix / confusion_matrix.sum(axis=1)[np.newaxis].T

## Plot
textcolors = ("black", "white")
fig, ax = plt.subplots()
img = ax.imshow(confusion_matrix, cmap=plt.cm.Blues)
for i in range(confusion_matrix.shape[0]):
    for j in range(confusion_matrix.shape[1]):
        ax.text(
            j, i, "{:.2f}".format(confusion_matrix[i, j]),
            ha="center", va="center",
            color=textcolors[confusion_matrix[i, j] > 0.5]
        )

plt.colorbar(img)
plt.title(f"Normalized Confusion Matrix (ResNet{args.model[-2:]})")
plt.xlabel("Predicted Label")
plt.ylabel("True Label")

pretrained_str = "w" if args.pretrained else "wo"

plt.savefig(f"{args.result_path}/cm_{args.model}_{pretrained_str}_pretrained.png")
```

上面是我 plot confusion matrix 的 code，input 會是 ground truth label 以及 prediction，因為總共有 5 個 class，所以 confusion matrix 會使一個 5*5 matrix，其中(i, j)代表的是 ground truth = i 被 predict 成 j 的 sample 數量，所以走訪一次 prediction list 就可以把 confusion matrix 計算出來，有計算好的 5*5 confusion matrix 後使用 plt 畫出來。

3. Data preprocessing

甲、How you preprocessing your data?

```
for i in tqdm(glob.glob(os.path.join("data", "*.jpeg"))):
    new_path = i.replace('data', 'processed_data')
    img = Image.open(i)
    width, height = img.size
    new_width = min(width, height)

    left = (width - new_width)/2
    top = (height - new_width)/2
    right = (width + new_width)/2
    bottom = (height + new_width)/2

    # Crop the center of the image
    im = img.crop((left, top, right, bottom))
    im = im.resize((512, 512))
    im = im.save(new_path)
```

我把圖片讀進來之後，取 min(width, height)當作新圖片的長寬，會想這樣取是因為觀察到每張圖片長寬都不一定，並且幾乎都是上下的眼

睛會被切割到，所以直接取短邊當做新圖的長寬可以最小化流失的資料，計算出 **center crop** 的上下左右座標，使用 **PIL crop** 擷取圖片中間的部分，之後再把他 **resize** 成 **512*512**，另外存起來。

乙、What makes your method special?

這個方法很簡單，沒有使用到 **detection** 的部分，所以執行起來會比較快，另外幾乎沒有 **data loss**，並且因為是 **center crop** 成正方形，所以 **resize** 後眼睛還是會是正圓，在 **data preprocessing** 完把比較小的圖片存起來，之後 **data loader** 讀檔案的時候應該是會比較快。

4. Experiments result

甲、The highest testing accuracy

ResNet18	With pretrain	0.8219
	Without pretrain	0.7340
ResNet50	With pretrain	0.8288
	Without pretrain	0.7335

i. Screenshot

```
Build dataset...
> Found 28899 images...
  Number of each class: {0: 28655, 1: 1955, 2: 4210, 3: 698, 4: 581}
> Found 7823 images...
  Number of each class: {0: 5153, 1: 488, 2: 1082, 3: 175, 4: 127}

Build model...
Using resnet50, w/ pretrained parameters...


/home/shlu2240/anaconda3/envs/dlp/python3.9/site-packages/torchvision/models/_utils.py:208: UserWarning: The parameter 'pretrained' is deprecated since 0.13 and may be removed in the future, please use 'weights' instead.
  warnings.warn(
/home/shlu2240/anaconda3/envs/dlp/python3.9/site-packages/torchvision/models/_utils.py:223: UserWarning: Arguments other than a weight enum or 'None' for 'weights' are deprecated since 0.13 and may be removed in the future. The current behavior is equivalent to passing 'weights=ResNet50_Weights.IMAGENET1K_V1'. You can also use 'weights=ResNet50_Weights.DEFAULT' to get the most up-to-date weights.
  warnings.warn(msg)
Build trainer...
Loading model checkpoint from ./checkpoints/resnet50_w_pretrained.pt
Test only...
100% | 220/220 [01:19<00:00, 2.77it/s]
Test Accuracy: 0.8288
```

ii. Anything you want to present

上面的表格是兩種模型各自 **with pretrain/ without pretrain** 的 **testing accuracy**，可以看到 **ResNet50 with pretrain** 有最高的 **testing accuracy**，也可以發現 **pretrain weight** 對 **testing** 有很大的幫助，雖然 **ResNet50** 比 **ResNet18** 複雜很多，但是加上 **pretrain weight** 後 **ResNet18** 比 **ResNet50** 表現還好。

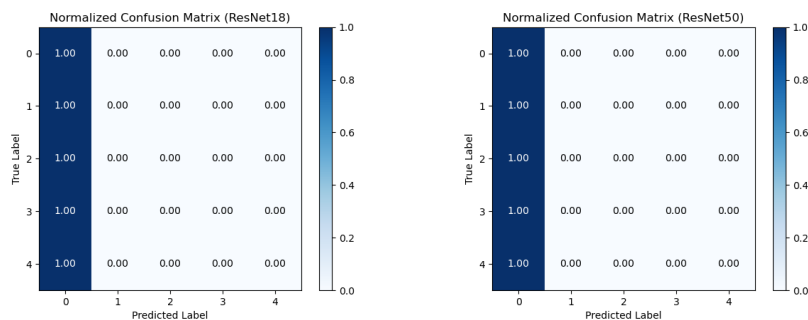
乙、Comparison figure

i. Plotting the comparison figures




上圖畫出各個模型各自 train test 的 accuracy curve，可以看出 pretrain weight 非常重要

ii. (ResNet18/50, with/without pretraining)



上圖是沒有使用 pretrain weight 兩個模型的 confusion matrix，可以看出來所有的 sample 都被歸類到 class 0，因為資料集中大部分的 sample 都是 class 0，所以模型只要不管怎樣都預測 class 0 就可以得到蠻低的 loss，導致 performance 很差，後面可以看到要是使用 pretrain weight，就可以稍微解決這個問題，可以讓模型更能學習到圖片中特徵跟 label 的對應。




上圖是兩個模型使用 **pretrain weight** 後訓練完的 **confusion matrix**，可以很明顯看出來比沒有使用 **pretrain weight** 好非常多，從這次實驗可以看出使用 **pretrain** 在大型資料集的參數當初始參數可以解決資料集 **inbalance** 問題。

5. Discussion

甲、Anything you want to share

有注意到訓練資料非常不平衡，可以使用一些簡單的方法處理，像是在 **loss function** 給不同的類別不同的 **loss weight**，給那些比較少資料的類別更高的 **weight**，讓模型更注意這些類別，不然模型直接通通預測數量最多的那個類別也可以得到蠻小的 **loss**。



加上 **loss weight** 後的 **testing accuracy** 雖然有下降，但是從 **confusion matrix** 中可以看到模型不再是通通預測成 **class 0**，代表 **loss weight** 對 **imbalanced dataset** 是有幫助的。